

Neural Network 기초 Assignment1

이름: 장혜린

Part 1. 함수 (20 points)

1. Sigmoid를 z 에 대해 미분하세요. (2 points)

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\begin{aligned}\sigma'(z) &= \frac{e^{-z}}{(1+e^{-z})^2} = \frac{(1+e^{-z})^{-1}}{(1+e^{-z})^2} = \frac{1}{(1+e^{-z})} - \frac{1}{(1+e^{-z})^2} = \frac{1}{(1+e^{-z})} \left(1 - \frac{1}{1+e^{-z}}\right) \\ &= \sigma(z)(1 - \sigma(z))\end{aligned}$$

2. Mean Square Error를 w_i 에 대해 편미분하세요. (3 points)

$$MSE = J(W) = \frac{1}{2} \sum_{k=1}^K (y_k - o_k)^2$$

$$o_i = \mathbf{w}_i^T \mathbf{x} + b_i, (1 \leq i \leq K)$$

$$\begin{aligned}\frac{\partial J(W)}{\partial w_i} &= \frac{1}{2} \cdot 2 \sum (y_i - o_i) (y_i - o_i)' \\ &= \sum (y_i - o_i) (1 - o_i) \\ &= -\sum (y_i - o_i) x\end{aligned}$$

3. Logistic Regression의 Log Likelihood를 w_j 에 대해 편미분하세요. (3 points)

$$\log \text{likelihood} = J(W) = - \sum_{k=1}^K \{y_k \log p_k + (1 - y_k) \log(1 - p_k)\}$$

$$p_j = \sigma(z_i), z_i = \mathbf{w}_i^T \mathbf{x} + b_i, (1 \leq i \leq K)$$

$$\begin{aligned}\frac{\partial J(W)}{\partial w_i} &= - \sum \left(y_i \frac{\partial}{\partial w_i} \log p_i + (1 - y_i) \frac{\partial}{\partial w_i} \log(1 - p_i) \right) \\ &= - \sum \left(\frac{y_i p_i (1 - p_i) x}{p_i} + \frac{-(1 - y_i) p_i (1 - p_i) x}{1 - p_i} \right) \\ &= - \sum (y_i (1 - p_i) x - (1 - y_i) p_i x) \\ &= - \sum (y_i - p_i) x \quad \text{즉} \quad \sum (p_i - y_i) x\end{aligned}$$

4. 다음 식이 올바른 이유를 증명하세요. (5 points)

$$-\sum_{k=1}^K y_k \log(p_k) = -\log p_i, (1 \leq i \leq K)$$

K개의 classification 문제일때

ex) K=3. $[1, 0, 0], [0, 1, 0], [0, 0, 1]$ 처럼 one-hot encoding 가정하면

위 식 성립

5. Softmax-Cross Entropy를 z_i 에 대해 편미분하세요. (7 points)

$$CE = -\sum_{k=1}^K y_k \log(p_k), \quad p_i = \frac{e^{z_i}}{\sum e^{z_k}}$$

p_i 미분할때 case 분리 ($i=j$ 와 $i \neq j$)

$$i) i=j \quad \frac{\partial p_i}{\partial z_i} = \frac{e^{z_i} \cdot \sum e^{z_k} - e^{z_i} \cdot e^{z_i}}{(\sum e^{z_k})^2} = \frac{e^{z_i} (\sum e^{z_k} - e^{z_i})}{(\sum e^{z_k})^2} = \frac{e^{z_i}}{\sum e^{z_k}} \cdot \frac{\sum e^{z_k} - e^{z_i}}{\sum e^{z_k}} = p_i (1 - p_i)$$

$$ii) i \neq j \quad \frac{\partial p_i}{\partial z_j} = \frac{0 - e^{z_i} \cdot e^{z_j}}{(\sum e^{z_k})^2} = -\frac{e^{z_i}}{\sum e^{z_k}} \cdot \frac{e^{z_j}}{\sum e^{z_k}} = -p_i p_j$$

$$\frac{\partial CE}{\partial z_i} = -\sum y_k \frac{\partial p_k}{\partial z_i} = -y_i \frac{p_i(1-p_i)}{p_i} - \sum_{i \neq j} (y_j \frac{-p_i p_j}{p_j})$$

$$= -y_i(1-p_i) + \sum_{i \neq j} y_j p_i$$


$$= -y_i + \sum_j y_j p_i$$

$$= -y_i + p_i \sum_j y_j$$

$$= p_i - y_i \quad (\because \sum_j y_j = 1)$$

Part 2. 퍼셉트론 (15 points)

다음과 같은 구조의 퍼셉트론과 ■(=1), □(=0)을 평면좌표상에 나타낸 그림이 있습니다.



1. ■, □를 분류하는 임의의 b , w 를 선정하고 분류하는 과정을 보이세요. (5 points)

$$b = +1, w_1 = -2, w_2 = +2$$

$$(0,0) \rightarrow \varphi(1) = 1 \rightarrow \hat{y} = 1$$

$$(0,1) \rightarrow \varphi(1+2) = 1 \rightarrow \hat{y} = 1$$

$$(1,0) \rightarrow \varphi(1-2) = -1 \rightarrow \hat{y} = 0$$

$$(1,1) \rightarrow \varphi(1-2+2) = 1 \rightarrow \hat{y} = 1$$

2. Perceptron 학습 규칙에 따라 임의의 학습률 η 을 정하고 b , w 를 한 번 업데이트해 주세요. (5 points)

$$\eta = 0.01 \quad b \leftarrow b + 0.01 \times 0$$

$$w_1 \leftarrow w_1 + 0.01 \times 0$$

$$w_2 \leftarrow w_2 + 0.01 \times 0$$

$$b = +1, w_1 = -2, w_2 = +2$$

3. Adaline Gradient Descent에 따라 임의의 학습률 η 을 정하고 b , w 를 한 번 업데이트해 주세요. (5 points)

$$\eta = 0.01 \quad b \leftarrow b + 0.01 \times (-3)$$

$$w_1 \leftarrow w_1 + 0.01 \times 1$$

$$w_2 \leftarrow w_2 + 0.01 \times (-1)$$


$$b = 0.99, w_1 = -1.99, w_2 = 1.98$$

x_0	x_1	x_2	y	$w^T x$	$y - w^T x$
1	0	0	1	1	0
1	0	1	1	3	-2
1	1	0	0	-1	1
1	1	1	1	1	0

Part 3. 다층 퍼셉트론 (30 points)

Input Layer가 2차원, 첫 번째 Hidden Layer가 4차원 첫 번째 활성화 함수가 ReLU, 두 번째 Hidden Layer가 3차원, 두 번째 활성화 함수가 Sigmoid, Output Layer가 2차원인 다층 퍼셉트론 구조의 신경망이 있습니다.

1. 위 신경망의 구조를 간략하게 그림으로 그리세요. (5 points)



2. Bias를 포함하여 각 Layer에 존재하는 Weight(Parameter)의 개수와 전체 Weight의 개수를 구하세요. (10 points)

Input layer : 3

hidden layer 1 : 5

hidden layer 2 : 4

output layer : 2

$$\text{total} = 3 \times 5 \times 4 \times 2 = 120$$

3. 위 신경망을 식으로 나타낼 때 필요한 함수, 벡터와 행렬을 정의하고 순전파 과정을 행렬 식으로 표현하세요. (ex) input: $x = (x_1, x_2, \dots)^T$, x 는 4x1차원) (15 points)

$$x = (x_1, x_2)^T, x \in \mathbb{R}^{2 \times 1}$$

$$W_1 = \begin{pmatrix} w_{11}^1 & w_{21}^1 & w_{31}^1 & w_{41}^1 \\ w_{12}^1 & w_{22}^1 & w_{32}^1 & w_{42}^1 \end{pmatrix}^T, W^1 \in \mathbb{R}^{4 \times 2}$$

$$b^1 = (b_1^1, b_2^1, b_3^1, b_4^1)^T, b^1 \in \mathbb{R}^{4 \times 1}$$

$$W^2 = \begin{pmatrix} \tilde{w}_{11}^2 & \tilde{w}_{21}^2 & \tilde{w}_{31}^2 \\ \tilde{w}_{12}^2 & \tilde{w}_{22}^2 & \tilde{w}_{32}^2 \\ \tilde{w}_{13}^2 & \tilde{w}_{23}^2 & \tilde{w}_{33}^2 \\ \tilde{w}_{14}^2 & \tilde{w}_{24}^2 & \tilde{w}_{34}^2 \end{pmatrix}^T, W^2 \in \mathbb{R}^{3 \times 4}$$

Tobig's 13기 이지용

$$b^2 = (b_1^2, b_2^2, b_3^2)^T, b^2 \in \mathbb{R}^{3 \times 1}$$

$$W^3 = \begin{pmatrix} w_{11}^3 & w_{21}^3 \\ w_{12}^3 & w_{22}^3 \\ w_{13}^3 & w_{23}^3 \end{pmatrix}^T, W^3 \in \mathbb{R}^{2 \times 3}$$

$$b^3 = (b_1^3, b_2^3)^T, b^3 \in \mathbb{R}^{2 \times 1}$$

$$z^1 = W^1 x + b^1$$

$$a^1 = \text{ReLU}(z^1)$$


$$z^2 = W^2 a^1 + b^2$$

$$a^2 = \text{sigmoid}(z^2)$$

$$z^3 = W^3 a^2 + b^3$$

Part 4. 역전파 (35 points)

1. 다음 그림들의 물음표에 들어갈 숫자를 구하세요. (5 points)



2. 3-3에서 정의한 함수, 벡터와 행렬로 각 Layer에 존재하는 Bias값들의 업데이트를 행렬식으로 표현하세요. (15 points)

$$\delta^3 = \frac{\partial J}{\partial z^3}$$

$$f^2 = \frac{\partial J}{\partial z^2} = f'(z^2) \Sigma w^3 \delta^3$$

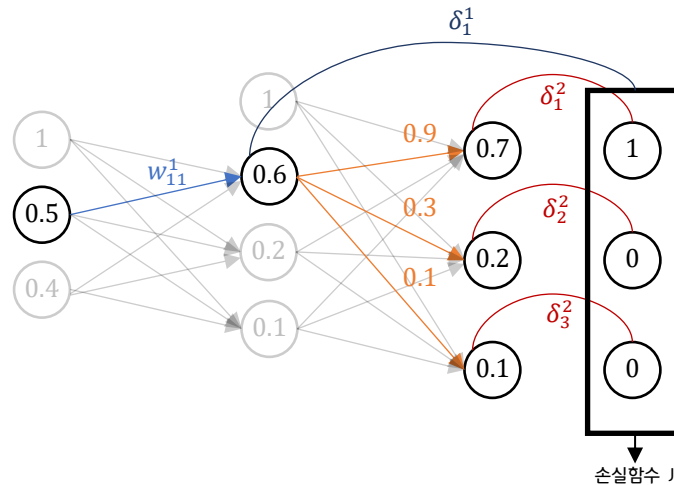
$$\delta^1 = \frac{\partial J}{\partial z^1} = f'(z^1) \Sigma w^2 f^2$$

$$b^3 \leftarrow b^3 - \eta \delta^3$$

$$b^2 \leftarrow b^2 - \eta f^2$$

$$b^1 \leftarrow b^1 - \eta f^1$$

3. 다음 그림에서 Loss Function은 Cross Entropy, Output Layer의 Activation Function은 Softmax, Hidden Layer의 Activation Function은 Sigmoid이고 Learning Rate는 0.05일 때, 각 δ 의 값과 w_{11}^1 의 변화량을 구하세요. (각 노드의 숫자는 활성화 이후의 숫자입니다.) (15 points)



$$\delta_1^2 = 1 - 0.7 = 0.3$$

$$\delta_2^2 = 0 - 0.2 = -0.2$$

$$\delta_3^2 = 0 - 0.1 = -0.1$$

$$\delta_1^1 = f'(0.6) (0.9 \delta_1^2 + 0.3 \delta_2^2 + 0.1 \delta_3^2)$$

$$= 0.6 (1 - 0.6) \times 0.2$$

$$= 0.048$$

$$\Delta w_{11}^1 = 0.05 \times \delta_1^1 \times x_1$$

$$= 0.05 \times 0.048 \times 0.5$$

$$= 0.0012$$

고생하셨습니다~