<Playing Atari with Deep Reinforcement Learning 논문 리뷰>

- **Abstract**

  - 강화학습을 이용한 첫번째 딥러닝 모델이며, high-dimensional sensory input인 pixel을 직접 받아 처리한다.
  - CNN 모델을 사용하며, input은 raw pixel이고, output은 value function이다.
  - 게임마다 network는 바꾸지 않은 채 Atari 2600에서 7개의 게임에 적용해보았는데, 3개의 게임에서는 사람을 능가했다.

- **1. Introduction: 풀고자 하는 문제 (Challenge)**

  - high-dimensional sensory input을 direct로 입력 받고 싶었으나 기존까지는 어려웠다.
  - 대부분의 RL(reinforcement learning)은 hand-crafted features에 의존해야 했다.

⇨ CNN, Multilayer perceptron 등 Neural Network를 통해 문제를 해결하고자 함.

but, 대부분의 DL(deep learning)은 hand-labelled된 데이터를 사용하지만, RL은 그렇지 못하다. 또한, DL은 독립적인 데이터를 가정하는데, RL은 sequence로서 correlated data를 사용한다.

⇨ 해결책:

1) hand-labelled data -> Q-learning

2) correlated data -> experience replay

* correlated data일 경우, 아래 그림과 같이 최적의 선과 다르게 학습될 수 있음.

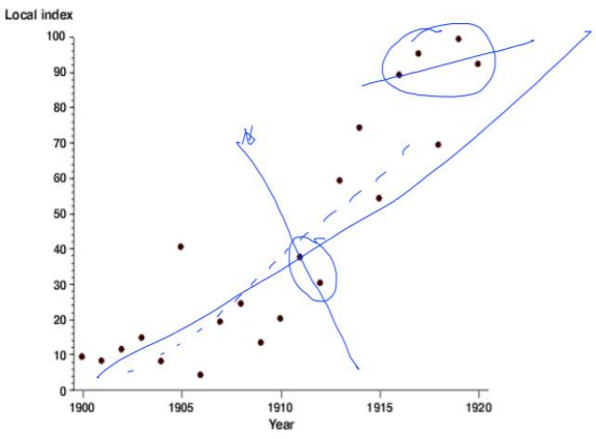

- **2. Background**

  - State: sequences of actions and observations
  - Value function: Bellman equation으로부터 Q(s,a) 정의
  - Q-Network:

    1) 기존의 Q-table로 표현하기에는 상태공간이 크기 때문에 network로 표현한다.

    2) Q(s,a,**w(weight)**)가 optimal한 Q(s,a)(=target 또는 y)와 근사하도록 하는 것이 목표이다. Stochastic gradient descent를 통해 loss function을 최소화하는 방향으로 weight를 학습한다.

$$l = \left(r + \gamma \max_a Q(s', a', \mathbf{w}) - Q(s, a, \mathbf{w}) \right)^2$$

* 참고로, Q-table에서는 optimal한 Q(s,a)를 찾을 수 있었던 것에 반해, neural net을 사용할 경우에는 수렴이 안되었었는데, Experience Replay를 통해 해결하였다.

* Non-stationary targets: target과 Q(s,a,w)가 같은 네트워크를 사용할 경우, weight이 변경이 될 때 target도 같이 변화한다는 문제가 발생한다. (활을 쏘는데, 과녁도 같이 움직인다고 생각하면 됨) -> 네트워크 분리 (target network 생성)

$$\min_\theta \sum_{t=0}^{T} [\hat{Q}(s_t, a_t|\theta) - (r_t + \gamma \max_{a'} \hat{Q}(s_{t+1}, a'|\bar{\theta}))]^2$$

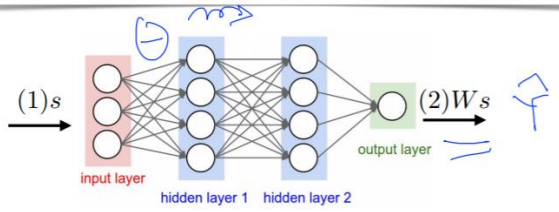

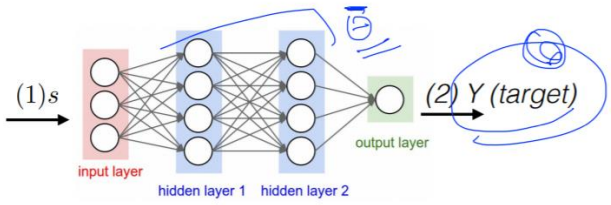

Sample random minibatch of transitions $(\phi_j, a_j, r_j, \phi_{j+1})$ from D

Set $y_j = \begin{cases} r_j & \text{if episode terminates at step j+1} \\ r_j + \gamma \max_{a'} \hat{Q}(\phi_{j+1}, a'; \theta^-) & \text{otherwise} \end{cases}$

Perform a gradient descent step on $\left(y_j - Q(\phi_j, a_j; \theta)\right)^2$ with respect to the network parameters θ

Every C steps reset $\hat{Q} = Q$

■ model-free algorithm: 가치함수 계산 시, 샘플링 기법 (모델 기반 강화학습과 달리 환경이 어떻게 동작되는지 알지 못한다. 즉, 주어진 상태에서 에이전트는 어떤 행동을 하고, '수동적으로' 환경을 알려주는 다음 번 상태의 보상을 얻게 된다.)

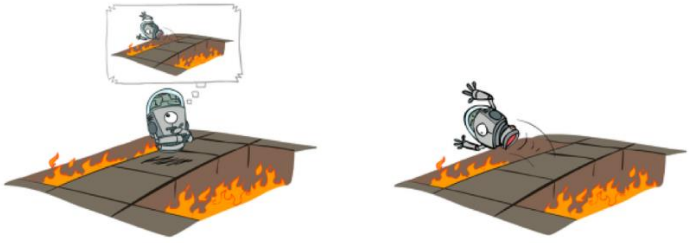

[그림 4] 모델 기반 강화 학습(Model-based RL)과 모델 프리 강화 학습(Model-free RL)

■ off-policy: behavior distribution(행동정책)은 e-greedy를 사용하고, 타깃정책은 greedy로, 다음 상태에서 취할 행동 중 행동가치가 가장 큰 행동을 선택한다.

* 현재 행동을 선택하는 행동정책과 가치함수를 학습하기 위해 다음 상태에서 행동을 선택하는 타깃정책이 다른 것을 off-policy라고 한다.

* e-greedy: 행동이 선택될 확률을 epsilon으로 조정한다. 최적 행동 외에 모든 행동이 확률적으로 선택될 가능성이 있다. (-> exploration)

- **3. Related Work**

■ TD-gammon:

1) Q-learning과 유사한 model-free algorithm

2) value function 계산하는데 multi-layer perceptron 사용한다.

3) backgammon에서만 적용 가능하다

4) Q-learning과 같은 model-free 알고리즘을 non-linear function approximator나 off-policy learning에 적용하면 Q-network는 수렴하지 않는다.

■ Deep neural network와 RL 결합:

1) divergence issue: gradient temporal-difference의 경우 non-linear function approximator로 fixed policy를 사용할 때 또는 제한적인 Q-learning 변형으로 linear function approximation과 함께 control policy를 학습할 때 수렴함을 증명하였다.

2) 그러나 nonlinear control까지는 확장되지 못하였다.

■ neural fitted Q-learning (NFQ):

1) RPROP gradient descent algorithm을 사용해 Q-network의 파라미터를 업데이트 함으로써 loss function을 최적화시킨다.

2) batch update: 데이터셋 사이즈에 비례하여 연산량 발생. 반면, 해당 논문은 stochastic gradient update로 연산량을 줄였다.

3) deep autoencoder: task의 low dimensional representation을 학습하여 간단한 real-world control task에 성공적으로 적용시켰다. 반면 해당 논문은 end-to-end learning으로 visual input을 직접 사용하였다.

- 4. Deep Reinforcement Learning

■ RL을 deep neural network와 연결해 RGB 이미지를 직접 다루고, stochastic gradient update를 사용해 데이터를 효율적으로 처리하는 것이 이 논문의 목표이다.

■ 적용된 기법: Experience Replay

1) Agent가 매 time-step마다 했던 experience(episode)들을 replay memory에 저장한다.

* 전처리 함수 ϕ를 사용하여 고정 길이의 history(state)를 입력으로 받는다.

2) replay memory로부터 랜덤하게 하나를 추출해 학습에 적용시킨다.

3) experience replay 이후 agent는 e-greedy에 따라 행동을 선택하고 수행한다.

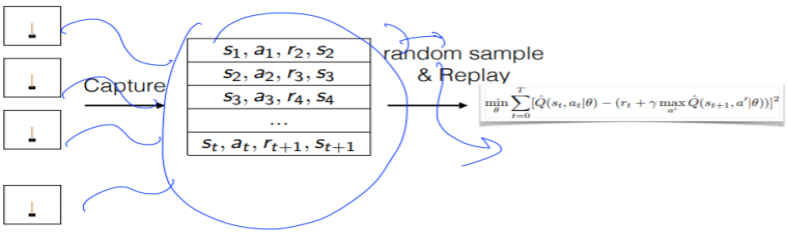

Algorithm 1 Deep Q-learning with Experience Replay

Initialize replay memory $\mathcal{D}$ to capacity N
Initialize action-value function Q with random weights
for episode $= 1, M$ **do**
  Initialise sequence $s_1 = \{x_1\}$ and preprocessed sequenced $\phi_1 = \phi(s_1)$
  for $t = 1, T$ **do**
    With probability ϵ select a random action a_t
    otherwise select $a_t = \max_a Q^*(\phi(s_t), a; \theta)$
    Execute action a_t in emulator and observe reward r_t and image x_{t+1}
    Set $s_{t+1} = s_t, a_t, x_{t+1}$ and preprocess $\phi_{t+1} = \phi(s_{t+1})$
    Store transition $(\phi_t, a_t, r_t, \phi_{t+1})$ in $\mathcal{D}$
    Sample random minibatch of transitions $(\phi_j, a_j, r_j, \phi_{j+1})$ from $\mathcal{D}$
    Set $y_j = \begin{cases} r_j & \text{for terminal } \phi_{j+1} \\ r_j + \gamma \max_{a'} Q(\phi_{j+1}, a'; \theta) & \text{for non-terminal } \phi_{j+1} \end{cases}$
    Perform a gradient descent step on $(y_j - Q(\phi_j, a_j; \theta))^2$ according to equation 3
  end for
end for

➔ 장점:

1) data efficiency: each step의 episode가 잠재적으로 많은 weight update에 재사용되므로 효율적이다.

2) break correlations: 연속적인 sample로부터 학습을 진행하는 것은 데이터들 간의 high correlation 때문에 비효율적이다. 에피소드의 순서를 무작위로 하여 데이터들 간의 상관관계를 break함으로써 update의 variance를 줄인다.

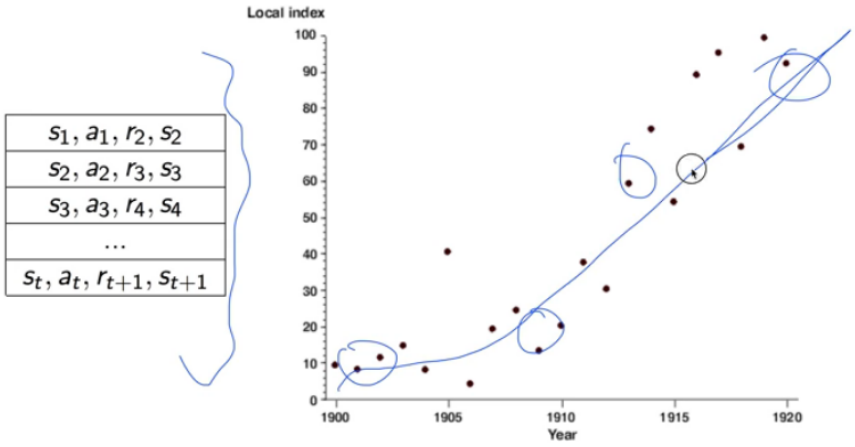

3) avoiding oscillations or divergence: off-policy 사용 전제

* 개선점: replay memory buffer는 transition(episode) 간에 차별성을 두지 않는다. 즉, buffer는 N개의 제한된 크기를 갖고 있으므로, 최근의 transition으로 덮어씌우는 한계가 있다. 정교한 sampling을 위해서는 중요한 에피소드일 경우 우선순위를 매길 필요가 있다.

- **4-1. Preprocessing and Model Architecture**

■ 210x160 pixel, 128 color palette인 image를 사용하는 것은 많은 연산량이 요구되므로, input의 dimensionality를 줄이기 위해 basic preprocessing step 과정을 거친다.

■ RGB -> gray-scale로 변환 & 110x84로 down-sampling한 후 84x84로 cropping(GPU 연산 위해)

■ 전처리 함수 ϕ에서 history의 마지막 4개의 frame만 전처리하여 stack에 두고 input 대한 Q-function을 구하기 위해 사용한다.

■ Q-value를 구하는 방법

1) (오른쪽 그림) history와 action을 input으로 하여 Q-value 예측

2) (왼쪽 그림) history만을 input으로 하여 각 행동에 대한 Q-value 예측

(single forward pass 이점 때문에 해당 논문에서는 두번째 방법을 사용하였다. 참고로, 첫번째 방법을 사용할 경우, 들어온 action에 따라 연산의 양도 linear하게 증가하게 된다.)

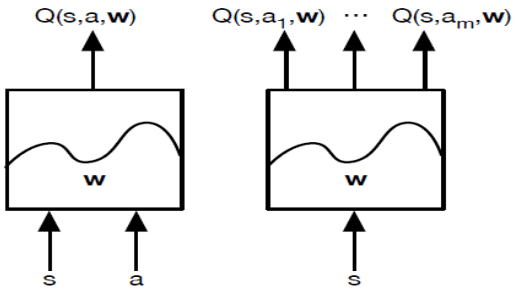

■ DQN in Atari

- End-to-end learning of values $Q(s, a)$ from pixels s
- Input state s is stack of raw pixels from last 4 frames
- Output is $Q(s, a)$ for 18 joystick/button positions
- Reward is change in score for that step

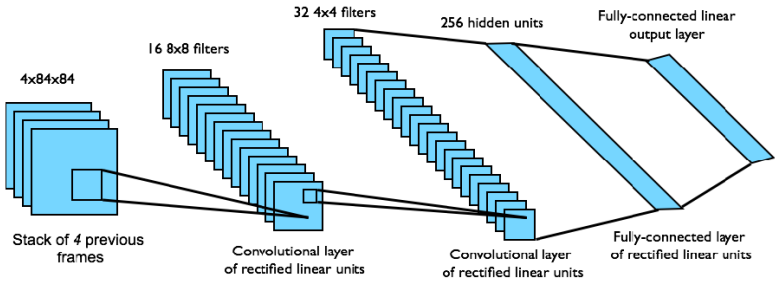

- **5. Experiments**

■ 6개의 Atari games에 대해 실험했고, 이 때 같은 network architecture, learning algorithm, hyperparameters setting을 사용했다. 즉, 다양한 게임에서도 robust하게 작동한다는 것을 보여준다.

■ training을 하면서 reward structure에 한가지 변화를 주었는데, score의 scale에 있어 양의 보상은 1, 음의 보상은 -1, 변화없음은 0으로 고정하였다. 이를 통해 error derivatives의 스케일을 제한하고 모든 게임에 동일한 learning rate를 사용하기에 용이했다.

■ minibatch size가 32인 RMSProp algorithm 사용

■ 행동 정책에서 e-greedy를 할 때, 100만번째 frame까지는 1에서 0.1까지 동일한 비율로 감소하는 epsilon 값을 사용했고, 이후에는 0.1로 고정했다.

■ frame-skipping technique 사용: agent가 모든 frame을 보는 것이 아니라 k번째 frame을 보고 액션을 선택한다. 그리고 마지막 행동은 skipped frames에 반복 적용시킨다. 이를 통해 k배 더 많이 게임을 진행시킬 수 있었다.

- 5-1. Training and Stability

■ Supervised learning과 달리 RL은 agent의 progress를 평가하는 것이 어렵다. 해당 논문에서는 평가의 척도로 average total reward를 사용한다.

■ 학습을 진행하면서 policy의 weight을 작게 변화시키더라도 state의 distribution에는 큰 변화를 미치므로 average total reward값은 변동이 크다.

■ 이론적인 증명은 부족하지만, Q-network를 사용해도 Q(s,a)가 수렴한다는 것을 Figure 2를 통해 보여준다.

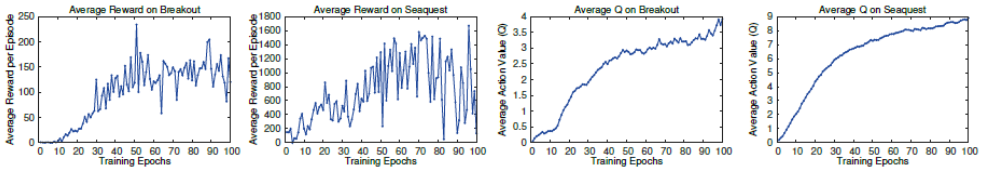

Figure 2: The two plots on the left show average reward per episode on Breakout and Seaquest respectively during training. The statistics were computed by running an ϵ-greedy policy with $\epsilon = 0.05$ for 10000 steps. The two plots on the right show the average maximum predicted action-value of a held out set of states on Breakout and Seaquest respectively. One epoch corresponds to 50000 minibatch weight updates or roughly 30 minutes of training time.

- 5-2. Visualizing the Value Function

■ 게임이 진행되는 화면 A,B,C에 따라 value function이 잘 반영하고 있는 것을 Figure3를 통해 보여준다.

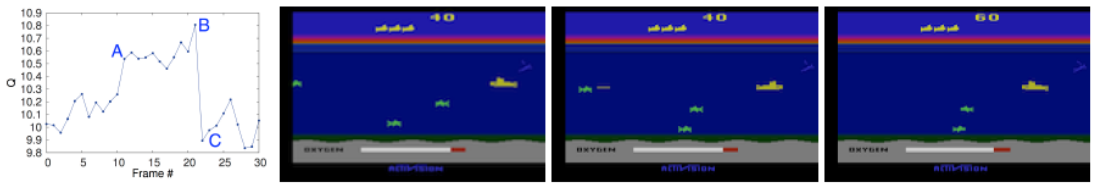

Figure 3: The leftmost plot shows the predicted value function for a 30 frame segment of the game Seaquest. The three screenshots correspond to the frames labeled by A, B, and C respectively.

- **5-3. Main Evaluation**

  - DQN의 성능이 다른 알고리즘보다 좋았음을 Tabel1을 통해 보여준다. (Space Invaders 제외)

  - Breakout, Enduro, Pong 게임에서는 사람보다 잘했다.

	B. Rider	Breakout	Enduro	Pong	Q*bert	Seaquest	S. Invaders
Random	354	1.2	0	−20.4	157	110	179
Sarsa [3]	996	5.2	129	−19	614	665	271
Contingency [4]	1743	6	159	−17	960	723	268
DQN	**4092**	**168**	**470**	**20**	**1952**	**1705**	**581**
Human	7456	31	368	−3	18900	28010	3690
HNeat Best [8]	3616	52	106	19	1800	920	**1720**
HNeat Pixel [8]	1332	4	91	−16	1325	800	1145
DQN Best	**5184**	**225**	**661**	**21**	**4500**	**1740**	1075

Table 1: The upper table compares average total reward for various learning methods by running an ϵ-greedy policy with $\epsilon = 0.05$ for a fixed number of steps. The lower table reports results of the single best performing episode for HNeat and DQN. HNeat produces deterministic policies that always get the same score while DQN used an ϵ-greedy policy with $\epsilon = 0.05$.

- **6. Conclusion**

  - RL을 위한 새로운 deep learning model을 소개하였다.

  - raw pixels input만으로 어려운 control policy를 학습하였다.

  - SGD와 experience replay를 적용한 Q-learning의 변형을 보였다.

  - architecture 또는 hyperparameters의 변화없이 7개의 게임 중 6개의 게임에서 뛰어난 성능을 보여주었다.

- 참고

  - Sung Kim, 유튜브 강의

    https://www.youtube.com/watch?v=V7_cNTfm2i8&feature=youtu.be

    https://www.youtube.com/watch?v=S1Y9eys2bdg&t=358s

  - David Silver, Tutorial: Deep Reinforcement Learning

    https://icml.cc/2016/tutorials/deep_rl_tutorial.pdf

  - Model-free based RL

    https://brunch.co.kr/@kakao-it/73

    [기초부터 시작하는 강화학습/신경망 알고리즘] 도서

  - experience replay

    https://poqw.github.io/DQN/

  - 논문 번역

    https://mangkyu.tistory.com/60